


葛飞翔

电话: 19857950790 邮箱: marshall_gefxiang@163.com

研究兴趣: 大模型分布式系统; 深度学习算法



2025.09 ~ 至今

教育经历

中国科学院大学 | 推免硕士研究生

人工智能

上海对外经贸大学 | 本科

2021.09 ~ 2025.06

数据科学与大数据技术

- 学业表现: GPA: 3.74/4.00; 专业排名: 1/39; 综测排名: 2/153; CET-4: 615; CET-6: 554。
- 相关课程: 算法导论 (97)、人工智能 (96)、深度学习 (96)、数字图像处理 (95)、分布式计算 (95)。

研究工作

Using Domain Adapter and Prompt Learner for Few-shot Teaching Action Recognition in videos

- 论文信息: Feixiang Ge, Xinlei Li, Yan Rong, et al., IJCNN 2025, Accepted, to be published; 第一作者, CCF-C。
- 方法贡献: 提出基于 CLIP 视觉-语言大模型的 TBA-CLIPNet, 面向小样本及零样本识别; 引入领域适配器弥补预训练大模型与下游任务间的语义鸿沟, 构建提示模板学习器从图像特征中自动学习提示模板; 设计教师目标识别算法 TD, 并利用时空自注意力机制提取视频时序信息。

A Hybrid CNN-Transformer Network for Fine-Grained Tongue Multi-Attribute Classification with Tongue Group Attribute Mask Training in Traditional Chinese Medicine Diagnosis

- 论文信息: Liu J, Ge F, Li F, et al., International Conference on Intelligent Computing, Springer Nature Singapore, 2025: 467-479; 共同一作, CCF-C。

可拓基元提取以及可拓知识论坛系统

软件著作权

- 登记号: 2024SR0643195; 第一著作权人。

业界工作

百度 | 混合云模型适配组 | 模型适配与推理性能优化

2026.02 ~ 至今

DeepSeek-V3.2 单机与 PD 分离推理调优

- 性能优化: 面向昆仑芯 P800, 基于 SGLang 与 vLLM-Kunlun 对齐算子链路, 围绕 NSA Indexer、MTP/投机解码和上下文并行开展细粒度打点、框架逻辑对齐与关键函数优化; 相关 NSA Indexer BF16 优化已合入。
- 量化结果: 单机性能较原准出版本大幅提升, 在不同并发与输入长度场景均取得显著收益。PD 分离 Router 方案较上一版提升 10%-70%, 上下文并行使短文本性能平均提升约 30%; 定位投机解码导致的乱码问题并通过关闭相关路径恢复精度。

P800 大模型适配与客户场景准出

- 模型适配: 完成 Qwen3/Qwen3.5 系列模型的推理适配、性能精度验证和准出文档; 定位 prompt_logprobs 算子兼容、vLLM 版本差异、prefix cache、CUDA Graph、xgrammar 与 XCCL 等问题。
- 场景覆盖: 参与 ASR、Grounding SAM、OpenFold/SAM3、BEVFormer 等模型在 P800 上的训练或推理适配; 针对长文本与超长上下文需求, 推进显存管理、量化模型和推理链路优化。

vLLM-Omni 升级与多模态推理优化

- 框架升级: 重构 Kunlun Plugin 与开源 vLLM-Omni 的 patch 解耦方式, 同步上游特性, 输出标准镜像与 SOP; 完成 Wan、Qwen-Image、GLM-Image、Qwen-Image-Edit 等多个模型的适配和初步精度/性能准出, 整体调优提升 50%-100%+。
- 性能结果: Wan 系列文本到视频模型推理耗时大幅下降; GLM-Image 达到 H20 的 80%-100% 性能且精度符合预期, Qwen-Image-Edit 达到 H20 的 50%。

Dynamo 分布式推理与 HiCache 性能分析

- 工程落地：完成 Dynamo 源码编译与部署，搭建 SGLang + HiCache + Dynamo 环境，验证 GLM 系列模型；修复 KV-aware 模式 DP rank 不一致导致的 Hang，解决前缀复用调度失效问题；修正 SGLang KV event 发布逻辑，完善 Dynamo 侧 event key (worker_id、DP rank) 管理；完成 HiCache 端到端测试，并调研 fast tokenization。
- 性能分析：在 Dynamo 与 Router 两侧注入 Prometheus 指标，拆解 tokenize、transport、dispatch、route 阶段；GLM 系列测试显示 TPOT 稳定提升 10%+，短文本 TTFT 提升 5%–20%，总吞吐有收益，并形成 Dynamo 方案进度与准出材料。

vLLM-Kunlun 开源贡献与平台提效

- 开源贡献：围绕 vLLM-Kunlun Workspace Manager 与昆仑芯显存管理提交并合入 [PR 283](#)；协助完成量化 patch 对齐及 Triton 算子替换 ([PR 409](#)、[PR 351](#)、[PR 381](#))。
- 标准化与赋能：迭代 LLM 部署 SOP Skill 与准出 Agent，自动化模型部署、性能/精度测试和结构化报告生成；编写 vLLM-Omni、DiT 优化、Dynamo 进度等技术材料，提升模型适配与交付效率。

eBay 软件工程有限公司 | AI Platform | 机器学习工程师 (Intern)

2024.10 ~ 2025.08

- 平台工程：深入实践 Ray Data、Ray Serve 等组件，解决多类型资源标签调度和 PyArrow 内存泄漏问题；相关修复已合入公司内部 Ray 分支 ([PR 49124](#)、[PR 49756](#))。
- 推理与工作流：修复 KubeRay 资源调度缺陷使 GPU 利用率翻倍，参与 AI 工作流框架开发，并探索 LLM 强化学习训练的资源需求、GPU 利用率与数据吞吐。

荣誉情况

- | | |
|-------------------------|------------------------|
| • 2024 年度上海市奖学金 | • 第十四届蓝桥杯国赛三等奖（国家级） |
| • 全国大学生市场调查分析大赛三等奖（国家级） | • 上海对外经贸大学优秀毕业生 |
| • 美国大学生数学建模竞赛 H 奖（国际级） | • 2023–2024 爱建特种基金会奖学金 |
| • 国科大杭州高等研究院新生奖学金 | • 上海对外经贸大学优秀共青团员 |